

HW_2_2025_Зиновьева_Екатерина



Часть 1

1. Рассчитайте метрику TF-IDF для любых трех песен на выбранном вами языке.

Были рассмотрены три песни: Король и Шут "Кукла колдуна", Бонд с кнопкой "Кухни", Xolidayboy "Тюлени"

[2]: #1 песня: Король и Шут "Кукла колдуна"

```
song_1 = '''  
Тёмный, мрачный коридор,  
Я на цыпочках, как вор,  
Пробираюсь, чуть дыша,  
Чтобы не спугнуть  
Тех, кто спит уже давно,  
Тех, кому не всё равно,  
В чью я комнату тайком  
Желаю заглянуть,  
Чтобы увидеть...  
  
Как бессонница в час ночной  
Меняет, нелюдимая, облик твой,  
Чьих невольница ты идей?  
Зачем тебе охотиться на людей?
```

```
  
Крестик на моей груди,  
На него ты погляди,  
Что в тебе способен он  
Резко изменить?  
Много книжек я читал,  
Много фокусов видал,  
Свою тайну от меня  
Не пытайся скрыть!  
Я это видел!
```

#2 песня: Бонд с кнопкой "Кухни"

```
song_2 = '''  
Простишь меня за всё или в одежде  
Тихо плакать, тихо плакать  
Когда устанешь, приходи, приходи, приходи  
На кухни  
В бережных и нежных хрущёвках  
Хранилище надежд для потомков  
Рассыпанная соль на клеёнке  
Молоко на губах обсохло  
Всё могло быть неплохо  
Всё могло быть неплохо  
Всё могло быть  
На этих кухнях  
Радостны дни твои  
Радостны дни твои  
Радостны дни твои  
Времени вагон жить  
Обувь не снимая  
Спать и расходиться  
По своим палатам  
Простишь за всё или в одежде  
Тихо плакать, безнадежно  
Когда устанешь, приходи, приходи, приходи  
На кухни
```

#3 песня: Xolidayboy "Тюлени"

```
song_3 = '''  
Нам трезвонят телефоны  
Но нам так наплевать  
У нас желание одно лишь  
Лежать! Лежать! Лежать!  
Она хочет, со мной хочет  
Этим утром, днём и ночью  
Целоваться, обниматься  
Плавниками прикасаться  
Она хочет, со мной хочет  
Этим утром, днём и ночью  
Мы в кровати две недели  
И валяться как тюлени  
Она хочет, со мной хочет  
Этим утром, днём и ночью  
Целоваться, обниматься  
Плавниками прикасаться  
Она хочет, со мной хочет  
Этим утром, днём и ночью  
Мы в кровати две недели  
И валяться как тюлени  
Я не буду снова про дела ваши слушать  
Дела — это скучно, дела — это душно  
Я хотел бы просто целовать твои ушки
```

Часть 1

1. Рассчитайте метрику TF-IDF для любых трех песен на выбранном вами языке.

Тексты были предобработаны: все слова приведены к нижнему регистру, удалены переносы строк и знаки препинания. Также удалены стоп слова - к стандартным так же были добавлены дополнительные слова, которые не несут ценности в обработке и часто встречаются в выбранных песнях

```
# Дополнительные стоп-слова
```

```
custom_stopwords = [  
    'это', 'этот', 'этим', 'этой',  
    'мной', 'мне', 'меня',  
    'тебе', 'тебя', 'твой', 'твои',  
    'нам', 'наш', 'наши',  
    'всё', 'весь', 'вся',  
    'свой', 'свои'  
]
```

ПРЕДОБРАБОТАННЫЕ ТЕКСТЫ:

Песня 1:

тёмный мрачный коридор цыпочках вор пробираюсь дыша спугнуть тех спит давно тех кому равно чью комнату тайком желаю заглянуть увидеть бессонница час ночной меняет нелюдимая облик чьих невольница идей охотиться людей крестик моей груди погляди способен резко изменить книжек читал фокусов видал тайну ...

Песня 2:

простишь одежде тихо плакать тихо плакать устанешь приходи приходи приходи кухни бережных нежных хрущёвках хранилище надежд потомков рассыпанная соль клеёнке молоко губах обсохло могло неплохо могло неплохо могло этих кухнях радостны дни радостны дни радостны дни времени вагон жить обувь снимая спат...

Песня 3:

трезвонят телефоны наплевать желание одно лишь лежать лежать лежать хочет хочет утром днём ночью целоваться обниматься плавниками прикасаться я хочет хочет утром днём ночью кровати две недели валяться тюлени хочет хочет утром днём ночью целоваться обниматься плавниками прикасаться хочет хочет утром дн...

Часть 1

1. Рассчитайте метрику TF-IDF для любых трех песен на выбранном вами языке.

Далее применен TF-IDF метод. Получена матрица TF-IDF, а также топ слов в каждой песне.


	безнадёжно	бережных	бессонница	буду	вагон	валяться \
song_1	0.000000	0.000000	0.184445	0.000000	0.000000	0.000000
song_2	0.062017	0.124035	0.000000	0.000000	0.062017	0.000000
song_3	0.000000	0.000000	0.000000	0.045011	0.000000	0.135034

	ваши	вдвоём	видал	видел ...	хранилище	хрущёвках \
song_1	0.000000	0.092222	0.092222	0.092222	...	0.000000
song_2	0.000000	0.000000	0.000000	0.000000	...	0.124035
song_3	0.045011	0.000000	0.000000	0.000000	...	0.000000


	целовать	целоваться	цыпочках	час	читал	чьих \
song_1	0.000000	0.000000	0.092222	0.276667	0.092222	0.184445
song_2	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
song_3	0.045011	0.135034	0.000000	0.000000	0.000000	0.000000

	чью	этих
song_1	0.092222	0.000000
song_2	0.000000	0.124035
song_3	0.000000	0.000000


Топ-10 слов: Кукла колдуна



Топ-10 слов: Кухни




Топ-10 слов: Тюлени



1. Рассчитайте метрику TF-IDF для любых трех песен на выбранном вами языке.

TF-IDF Heatmap



1. Рассчитайте метрику TF-IDF для любых трех песен на выбранном вами языке.


слово 'ночной' встречается в других песнях? Нет
слово 'час' встречается в других песнях? Нет
слово 'охотиться' встречается в других песнях? Нет
слово 'идей' встречается в других песнях? Нет
слово 'бессонница' встречается в других песнях? Нет
слово 'людей' встречается в других песнях? Нет
слово 'меняет' встречается в других песнях? Нет
слово 'невольница' встречается в других песнях? Нет
слово 'нелюдям' встречается в других песнях? Нет
слово 'чьих' встречается в других песнях? Нет



Часть 1

2. Сравните TF-IDF с другими методами векторизации текста, такими как Count Vectorizer, Word2Vec или Doc2Vec.

Далее были применены разные методы векторизации. В результате сравнения были получены следующие результаты. TF-IDF и CountVectorizer значительно быстрее Word2Vec и Doc2Vec, что делает их предпочтительными для анализа текстов когда важна скорость обработки и интерпретируемость результатов.



Часть 1




3. Проведите исследование, используя полученные преобразованные данные. Какие слова/фразы встречаются чаще всего, а какие реже.

Были проанализированы топ частых и редких слов в песнях.

CountVectorizer - выделяет самые часто встречающиеся слова, но не учитывает их уникальность.

TF-IDF - поднимает уникальные или значимые слова для каждой песни; редкие слова становятся заметными, а очень частые по всем песням снижаются.

Word2Vec - показывает частые слова по количеству встречаемости при обучении. Редкие слова встречаются мало, но семантически близкие могут группироваться вместе.




Часть 1

3. Проведите исследование, используя полученные преобразованные данные. Какие слова/фразы встречаются чаще всего, а какие реже.

На основе Word2Vec была построена t-sne визуализация.

На малом корпусе текстов в целом дает нестабильные результаты: из-за ограниченного объема данных и небольшой частоты слов многие векторы не отражают реальную семантическую схожесть. Тем не менее, даже на таком маленьком корпусе можно заметить смысловые связи между некоторыми словами - «**днём**» и «**ночной**» или «**губах**» и «**целоваться**» расположены рядом, что соответствует их контексту в текстах песен




Часть 2

4. Используйте предварительно обученную модель BERT для классификации тональности отзывов о фильмах.

Предобученная модель BERT была дообучена для задачи бинарной классификации тональности отзывов. На тестовой выборке модель показала Accuracy = 0.9043 и F1-score = 0.9108, что говорит о высоком качестве классификации и хорошем балансе между precision (0.8590) и recall (0.9692).

Матрица ошибок показала, что модель корректно распознаёт большинство положительных и отрицательных отзывов, при этом немного чаще относит нейтральные или спорные отзывы к положительному классу.

Среднее время обработки одного отзыва составляет примерно 0.02 секунды, что делает модель пригодной для практического применения. В целом, результаты подтверждают эффективность предобученной модели BERT для задачи анализа тональности текста.



Текст: This movie was absolutely fantastic. I really loved it!

Предсказание: Positive

Уверенность: 0.9950

Текст: Terrible movie. Waste of time.

Предсказание: Negative

Уверенность: 0.9979

Текст: It was okay, not great but not bad either.

Предсказание: Positive

Уверенность: 0.5019